

1 SMO 算法

1.1 简单回顾 SVM

在 SVM 中, 我们的目的是寻找两种不同类之间的超平面, 使其间隔最大化, 其中最大化间隔距离可以表示如下:

$$\max \frac{1}{\|\mathbf{w}\|} \quad s.t. \quad y_i(\mathbf{w}\mathbf{x}_i + b) \geq 1, \quad i = 1, \dots, n$$

进一步得到需要优化的目标函数:

$$\min_{\mathbf{w}, b} f(\mathbf{w}, b) = \frac{1}{2} \|\mathbf{w}\|^2 \quad s.t. \quad y_i(\mathbf{w}\mathbf{x}_i + b) \geq 1, \quad i = 1, \dots, n \quad (1)$$

该函数用拉格朗日乘子法转化成:

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^n \alpha_i [1 - y_i(\mathbf{w}\mathbf{x}_i + b)]$$

再由拉格朗日对偶把原问题变成:

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^n \alpha_i - \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j k_{ij} \\ s.t. \quad & \alpha_i \geq 0, \quad i = 1, \dots, n \\ & \sum_{i=1}^n \alpha_i y_i = 0 \end{aligned} \quad (2)$$

而 SMO 算法所做的, 就是求解这个式子。在这里, 先给出 KKT 条件和核函数的概念, 因为 SMO 算法是基于这些条件来进行的, **KKT 条件为:**

$$\begin{aligned} \alpha_i = 0 & \iff y_i(\mathbf{w}\mathbf{x}_i + b) \geq 1 \\ 0 \leq \alpha_i \leq C & \iff y_i(\mathbf{w}\mathbf{x}_i + b) = 1 \\ \alpha_i = C & \iff y_i(\mathbf{w}\mathbf{x}_i + b) \leq 1 \end{aligned} \quad (3)$$

核函数: 在支持向量机中, 我们的目的是寻找两种不同类之间的超平面的最大间隔, 而这个超平面一般是通过高维映射得到的, 那怎么实现高维映射呢, 答案正是核函数。核函数是一类功能性函数, 能够在支持向量机中实现高维映射的函数都称为核函数, 文中用 K_{ij} 表示。

1.2 什么是 SMO 算法

SMO 是 Sequential minimal optimization 的缩写, 译为序列最小优化算法, 是一种用于解决支持向量机训练过程中所产生优化问题的算法。SMO 的最初版本是由微软研究院的约翰·普莱特 (John C.Platt) 在《Sequential Minimal Optimization: A Fast Algorithm for Training Support Vector Machines》一文中提出的, 其基本思想是将原问题求解 $(\alpha_1, \alpha_2, \alpha_3, \dots, \alpha_n)$ 这 n 个参数的问题分解成多个子二次规划的问题分别求解, 每个子问题只需要求解其中的两个参数, 每次通过启发式选择两个变量进行优化, 不断循环, 直到达到函数的最优值。

接下来将用一个简单的例子来感受一下这个过程,

在 svm3-解决优化问题中的例子，有三个样本 p_1, p_2, p_2 ，其值为 (\mathbf{x}_i, y_i) 分别表示 p_i 的样本值和标签值)

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \\ \mathbf{x}_3 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 3 & 3 \\ 4 & 3 \end{bmatrix}, \mathbf{Y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} = \begin{bmatrix} -1 \\ +1 \\ +1 \end{bmatrix}$$

当时我们通过构造拉格朗日函数 $L(w, b, \alpha)$ 并求极值来得到优化问题下的 w, b, α 值，在这里我们通过 SMO 算法求解：

首先把 (2) 式展开：

$$\begin{aligned} W(\alpha) &= \alpha_1 + \alpha_2 + \alpha_3 - \frac{1}{2}[y_1 y_1 \alpha_1 \alpha_1 k_{11} + y_1 y_2 \alpha_1 \alpha_2 k_{12} + y_1 y_3 \alpha_1 \alpha_3 k_{13} + \\ &\quad y_2 y_1 \alpha_2 \alpha_1 k_{21} + y_2 y_2 \alpha_2 \alpha_2 k_{22} + y_2 y_3 \alpha_2 \alpha_3 k_{23} + \\ &\quad y_3 y_1 \alpha_3 \alpha_1 k_{31} + y_3 y_2 \alpha_3 \alpha_2 k_{32} + y_3 y_3 \alpha_3 \alpha_3 k_{33}] \\ &= \alpha_1 + \alpha_2 + \alpha_3 - \frac{1}{2}k_{11}\alpha_1^2 - \frac{1}{2}k_{22}\alpha_2^2 - \frac{1}{2}k_{33}\alpha_3^2 - y_1 y_2 \alpha_1 \alpha_2 k_{12} - y_1 y_3 \alpha_1 \alpha_3 k_{13} - y_2 y_3 \alpha_2 \alpha_3 k_{23} \end{aligned}$$

把

$$\begin{aligned} y_1 &= -1, y_2 = +1, y_3 = +1 \\ k_{11} &= \mathbf{x}_1 \cdot \mathbf{x}_1^T = \begin{bmatrix} 1 & 1 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 1 \end{bmatrix} = 2 \\ k_{22} &= \mathbf{x}_2 \cdot \mathbf{x}_2^T = \begin{bmatrix} 3 & 3 \end{bmatrix} \cdot \begin{bmatrix} 3 \\ 3 \end{bmatrix} = 18 \\ k_{33} &= \mathbf{x}_3 \cdot \mathbf{x}_3^T = \begin{bmatrix} 4 & 3 \end{bmatrix} \cdot \begin{bmatrix} 4 \\ 3 \end{bmatrix} = 25 \\ k_{12} &= k_{21} = \mathbf{x}_1 \cdot \mathbf{x}_2^T = \begin{bmatrix} 1 & 1 \end{bmatrix} \cdot \begin{bmatrix} 3 \\ 3 \end{bmatrix} = 6 \\ k_{13} &= k_{31} = \mathbf{x}_1 \cdot \mathbf{x}_3^T = \begin{bmatrix} 1 & 1 \end{bmatrix} \cdot \begin{bmatrix} 4 \\ 3 \end{bmatrix} = 7 \\ k_{23} &= k_{32} = \mathbf{x}_2 \cdot \mathbf{x}_3^T = \begin{bmatrix} 3 & 3 \end{bmatrix} \cdot \begin{bmatrix} 4 \\ 3 \end{bmatrix} = 21 \end{aligned}$$

带入得，

$$W(\alpha) = \alpha_1 + \alpha_2 + \alpha_3 - \alpha_1^2 - 9\alpha_2^2 - \frac{25}{2}\alpha^2 + 6\alpha_1\alpha_2 + 7\alpha_1\alpha_3 - 21\alpha_2\alpha_3 \quad (4)$$

由 (2) 式中的约束条件， $\alpha_1 y_1 + \alpha_2 y_2 + \alpha_3 y_3 = 0$ ，即 $-\alpha_1 + \alpha_2 + \alpha_3 = 0$ ，这里固定 α_3 ，即把 α_3 视为常数 γ ，则

$$\alpha_1 = \alpha_2 - \gamma$$

带入上式，得

$$W(\alpha) = f(\alpha_2) = -4\alpha_2^2 + (2 - 18\gamma)\alpha_2 - \frac{41}{2}\gamma^2 \quad (5)$$

对 $f(\alpha_2)$ 求导得

$$f'(\alpha_2) = -8\alpha_2 + 2 - 18\gamma$$

令 $f'(\alpha_2) = 0$ ，得

$$\alpha_2 = \frac{1}{4} - \frac{9}{2}\gamma, \quad \alpha_1 = \frac{1}{4} - \frac{11}{2}\gamma$$

通常 α 的初始值都设置为 0，所以这里 $\alpha_3 = \gamma = 0$ ，进而得到

$$\alpha_2 = \frac{1}{4}, \quad \alpha_1 = \frac{1}{4}$$

根据 svm5-解决对偶问题一节中可知，

$$\mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i$$

带入上面数据得到

$$\mathbf{w} = -\frac{1}{4} \begin{bmatrix} 1 & 1 \end{bmatrix} + \frac{1}{4} \begin{bmatrix} 3 & 3 \end{bmatrix} + 0 \cdot \begin{bmatrix} 4 & 3 \end{bmatrix} = \begin{bmatrix} \frac{1}{2} & \frac{1}{2} \end{bmatrix}$$

同样， b 的初始值一般为零，此时把 $\alpha_1, \alpha_2, \alpha_3, \mathbf{w}, b$ 带入 (3) 式，可知满足 KKT 条件，从而确定它们的值。

1.3 SMO 算法的详细推导

SMO 算法的目的就是求解 (2) 式，式子中，标签值 y_i ，核函数 k_{ij} 都是已知量，因此该式子可以写成自变量为 α ，因变量为 $W(\alpha)$ 的目标求解函数：

$$\max W(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n y_i y_j \alpha_i \alpha_j k_{ij}$$

$$s.t. \alpha_i \geq 0, i = 1, \dots, n$$

$$\sum_{i=1}^n \alpha_i y_i = 0$$

我们来看，这个函数里有 n 个自变量 $\alpha_1, \alpha_2, \dots, \alpha_n$ ，若一次性计算求解，由高等数学我们知道可以分别对每个自变量 α_i 求偏导，再令其偏导数等于零进而求解，这个方法在数据量很小时或许可行，但一当遇到较大的数据量时，其计算量可想而知是非常麻烦且冗杂的。那我们能不能用其他办法来解决这个问题呢，答案是肯定的，SMO 算法就是众多求解方法中的一种快速有效的方法。

回到刚刚那个问题，我们既然一次性求解 α 值的方法不可行，那我们分多次求解呢，每次选择一部分 α 变量进行求解，剩下的 α 值我们视为常量，然后运用高等数学里面求偏导

的方法求解出满足条件的 α 值，不断重复以上步骤，直至矩阵 α 满足所需条件。空口无凭，那我们不妨尝试一下这个方法行不行，刚开始这里就遇到个问题，我们每部分求解的 α 值选几个合适呢，为了简单起见，我们就选一个吧，但这时我们回到目标函数中的约束条件 $\sum_{i=1}^n \alpha_i y_i = 0$ 会发现，这样的话选出来的这个 α_i 就等于 $-\frac{\sum_{j=1}^{n-1} \alpha_j y_j}{y_i}$ ，那这样 α_i 也是常量了，因此，只选一个 α 是不可行的，那我们选择两个呢，假设选出两个为 α_1, α_2 ，这时 $\alpha_1 y_1 + \alpha_2 y_2 = \sum_{j=1}^{n-2} \alpha_j y_j$ ，这就很好的解决了上面遇到的那个问题。

接下来，我们对选出来的 α_1, α_2 进行求解，为描述方便，在这里我们定义符号

$$\begin{aligned} K_{ij} &= K(\mathbf{x}_i, \mathbf{x}_j) \\ f(\mathbf{x}_i) &= \mathbf{w}\mathbf{x}_i + b = \sum_{j=1}^n y_j \alpha_j K_{ij} + b \\ \nu_i &= \sum_{j=3}^n y_j \alpha_j K_{ij} \end{aligned}$$

把 $W(\alpha_1, \alpha_2)$ 展开得到

$$\begin{aligned} W(\alpha_1, \alpha_2) &= \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^3 \sum_{j=1}^3 y_i y_j \alpha_i \alpha_j k_{ij} \\ &= \alpha_1 + \alpha_2 + \sum_{i=3}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \left(\sum_{j=1}^2 y_i y_j \alpha_i \alpha_j k_{ij} + \sum_{j=3}^n y_i y_j \alpha_i \alpha_j k_{ij} \right) \\ &= \alpha_1 + \alpha_2 + \sum_{i=3}^n \alpha_i - \frac{1}{2} \sum_{i=1}^2 \left(\sum_{j=1}^2 y_i y_j \alpha_i \alpha_j k_{ij} + \sum_{j=3}^n y_i y_j \alpha_i \alpha_j k_{ij} \right) \\ &\quad - \frac{1}{2} \sum_{i=3}^n \left(\sum_{j=1}^2 y_i y_j \alpha_i \alpha_j k_{ij} + \sum_{j=3}^n y_i y_j \alpha_i \alpha_j k_{ij} \right) \\ &= \alpha_1 + \alpha_2 + \sum_{i=3}^n \alpha_i - \frac{1}{2} \sum_{i=1}^2 \sum_{j=1}^2 y_i y_j \alpha_i \alpha_j k_{ij} - \sum_{i=1}^2 \sum_{j=3}^n y_i y_j \alpha_i \alpha_j k_{ij} - \frac{1}{2} \sum_{i=3}^n \sum_{j=3}^n y_i y_j \alpha_i \alpha_j k_{ij} \\ &= \alpha_1 + \alpha_2 - \frac{1}{2} K_{11} \alpha_1^2 - \frac{1}{2} K_{22} \alpha_2^2 - y_1 y_2 K_{12} \alpha_1 \alpha_2 - y_1 \alpha_1 \sum_{j=1}^n y_j \alpha_j K_{1j} \\ &\quad - y_2 \alpha_2 \sum_{j=3}^n y_j \alpha_j K_{2j} + \sum_{i=3}^n \alpha_i - \frac{1}{2} \sum_{i=3}^n \sum_{j=3}^n y_i y_j \alpha_i \alpha_j k_{ij} \\ &= \alpha_1 + \alpha_2 - \frac{1}{2} K_{11} \alpha_1^2 - \frac{1}{2} K_{22} \alpha_2^2 - y_1 y_2 K_{12} \alpha_1 \alpha_2 - y_1 \alpha_1 \nu_1 - y_2 \alpha_2 \nu_2 + Constant \end{aligned}$$

由上面我们知道， $\alpha_1 y_1 + \alpha_2 y_2 = \sum_{j=1}^{n-2} \alpha_j y_j$ ，因为其他的 α 都视为常量，所以 $\sum_{j=1}^{n-2} \alpha_j y_j$ 也是一个常量，令其等于 γ ，得到

$$\alpha_1 y_1 + \alpha_2 y_2 = \gamma$$

同乘 y_1 得

$$\alpha_1 = \gamma y_1 - y_1 y_2 \alpha_2$$

令 $\gamma y_1 = A, y_1 y_2 = B$, 得 $\alpha_1 = A - B \alpha_2$

带入上式

$$\begin{aligned} W(\alpha_2) = & A - B \alpha_2 + \alpha_2 - \frac{1}{2} k_{11} (A - B \alpha_2)^2 - \frac{1}{2} k_{22} \alpha_2^2 - B k_{12} y_1 y_2 (A - B \alpha_2) \alpha_2 \\ & - y_1 (A - B \alpha_2) \nu_1 - y_2 \alpha_2 \nu_2 + Constant \end{aligned}$$

对 $W(\alpha_2)$ 求导得:

$$\frac{dW(\alpha_2)}{d\alpha_2} = -B + 1 + ABk_{11} - k_{11}\alpha_2 - k_{22}\alpha_2 - ABk_{12} + 2k_{12}\alpha_2 + y_2\nu_1 - y_2\nu_2$$

令其等于零得到:

$$\begin{aligned} \alpha_2 = & \frac{-B + 1 + ABk_{11} - ABk_{12} + y_2\nu_1 - y_2\nu_2}{K_{11} + K_{22} - 2K_{12}} \\ = & \frac{y_2(y_2 - y_1 + y_1 A(K_{11} - K_{12}) + \nu_1 - \nu_2)}{K_{11} + K_{22} - 2K_{12}} \end{aligned} \quad (6)$$

我们把求解后的 α_i 称为 α_i^{new} , 求解前的 α_i 称为 α_i^{old} , 由约束条件我们可得:

$$\alpha_1^{new} y_1 + \alpha_2^{new} y_2 = \alpha_1^{old} y_1 + \alpha_2^{old} y_2 = \gamma$$

由

$$\begin{aligned} f(\mathbf{x}_i) = \mathbf{w}\mathbf{x}_i + b = & \sum_{j=1}^n y_j \alpha_j K_{ij} + b \\ \nu_i = & \sum_{j=3}^n y_j \alpha_j K_{ij} \end{aligned}$$

可得

$$\begin{aligned} \nu_1 = f(x_1) - \sum_{j=1}^2 y_j \alpha_j K_{1j} - b = & f(x_1) - \alpha_1 y_1 k_{11} - \alpha_2 y_2 k_{12} - b \\ \nu_2 = f(x_2) - \sum_{j=1}^2 y_j \alpha_j K_{2j} - b = & f(x_2) - \alpha_1 y_1 k_{21} - \alpha_2 y_2 k_{22} - b \end{aligned}$$

所以 (6) 式变为:

$$\begin{aligned} \alpha_2^{new} = & \frac{y_2[y_2 - y_1 + y_1(\alpha_1^{old} + y_1 y_2 \alpha_2^{old})(K_{11} - K_{12}) + (f(x_1) - \alpha_1 y_1 k_{11} - \alpha_2 y_2 k_{12} - b) - (f(x_2) - \alpha_1 y_1 k_{21} - \alpha_2 y_2 k_{22} - b)]}{K_{11} + K_{22} - 2K_{12}} \\ = & \frac{y_2(y_2 - y_1 + y_1(\alpha_1^{old} + y_1 y_2 \alpha_2^{old})(K_{11} - K_{12}) + f(x_1) - f(x_2) - \alpha_1 y_1 k_{11} - \alpha_2 y_2 k_{12} + \alpha_1 y_1 k_{21} + \alpha_2 y_2 k_{22})}{K_{11} + K_{22} - 2K_{12}} \\ = & \frac{y_2(y_2 - y_1 + y_1 \alpha_1^{old} k_{11} - y_1 \alpha_1 k_{12} + y_2 \alpha_2^{old} K_{11} - y_2 \alpha_2 K_{12} + f(x_1) - f(x_2) - \alpha_1 y_1 k_{11} - \alpha_2 y_2 k_{12} + \alpha_1 y_1 k_{21} + \alpha_2 y_2 k_{22})}{K_{11} + K_{22} - 2K_{12}} \\ = & \frac{y_2[\alpha_2^{old}(K_{11} + K_{22} - 2k_{12}) + (f(x_1) - y_1) - (f(x_2) - y_2)]}{K_{11} + K_{22} - 2K_{12}} \end{aligned}$$

令 $\eta = K_{11} + K_{22} - 2K_{12}$ 进而得到迭代式：

$$\alpha_{2new} = \alpha_{2old} + \frac{y_2(E_1 - E_2)}{\eta} \quad (7)$$

回到约束条件， α_2 需满足下面两个式子

$$0 \leq \alpha_2 \leq C$$

$$\alpha_1 y_1 + \alpha_2 y_2 = \gamma$$

对第二个式子做一下变换

$$\alpha_2 = -\frac{y_1}{y_2}\alpha_1 + \frac{\gamma}{y_2}$$

当 y_1, y_2 异号时， $\alpha_2 = \alpha_1 \pm \gamma$ ，当 y_1, y_2 同号时， $\alpha_2 = -\alpha_1 \pm \gamma$ 在直角坐标系中画出相关直线可直观的看出其取值范围，如图

$$L = \begin{cases} \max\{0, \alpha_{1old} + \alpha_{2old} - \gamma\} & y_1 y_2 = 1 \\ \max\{0, \alpha_{2old} - \alpha_{1old}\} & y_1 y_2 = -1 \end{cases}$$

$$H = \begin{cases} \min\{C, C + \alpha_{1old} - \alpha_{2old}\} & y_1 y_2 = -1 \\ \min\{C, \alpha_{2old} + \alpha_{1old}\} & y_1 y_2 = 1 \end{cases}$$

$$\alpha_{jnew,clipped} = \begin{cases} L & \alpha_{jnew} \leq L \\ \alpha_{jnew} & L < \alpha_{jnew} < H \\ H & \alpha_{jnew} \geq H \end{cases}$$

$$\alpha_{inew} = \alpha_{iold} + y_1 y_2 (\alpha_{jold} - \alpha_{jnew,clipped})$$

阈值 b 的计算

1、若 $0 < \alpha_2 < C$ ，由 $y_2 = f(\mathbf{x}_2) = \mathbf{w}\mathbf{x}_2 + b = \sum_{j=1}^n y_j \alpha_j K_{2j} + b$ 得

$$\begin{aligned} b^{new} &= b_2^{new} = y_2 - \sum_{j=3}^n y_j \alpha_j K_{2j} - \alpha_1^{new} y_1 K_{21} - \alpha_2^{new} y_2 K_{22} \\ &= y_2 - (f(x_2) - \alpha_1^{old} y_1 K_{21} - \alpha_2^{old} y_2 K_{22} - b^{old}) - \alpha_1^{new} y_1 K_{21} - \alpha_2^{new} y_2 K_{22} \\ &= y_2 - f(x_2) + \alpha_1^{old} y_1 K_{21} + \alpha_2^{old} y_2 K_{22} + b^{old} - \alpha_1^{new} y_1 K_{21} - \alpha_2^{new} y_2 K_{22} \\ &= y_1 K_{21} (\alpha_1^{old} - \alpha_1^{new}) + y_2 K_{22} (\alpha_2^{old} - \alpha_2^{new}) - E_2 + b^{old} \end{aligned}$$

2、若 $0 < \alpha_1 < C$ ，同理可得

$$b^{new} = b_1^{new} = y_1 K_{11} (\alpha_1^{old} - \alpha_1^{new}) + y_2 K_{21} (\alpha_2^{old} - \alpha_2^{new}) - E_2 + b^{old}$$

3、若 1、2 都满足，则 $b^{new} = b_1^{new} = b_2^{new}$

4、若 1、2 都不满足，则 $b^{new} = \frac{b_1^{new} + b_2^{new}}{2}$

至此，我们就求解出了 α_1, α_2 的值。回过头来看，我们如何选择合适的 α_1, α_2 成为一个非常关键的问题，在 SMO 算法中，我们通过启发式的选择方法选出 α_1 和 α_2 。

启发式的选择方法

第一个变量的选取

首先遍历整个样本后选择违反 KKT 条件的 α_i 作为第一个变量，通常称这一过程为外循环。违反 KKT 条件的 α 满足下面式子：

$$\begin{aligned}\alpha_i &= 0 \quad \&\& \quad y_i(\mathbf{w}\mathbf{x}_i + b) < 1 \\ 0 \leq \alpha_i &\leq C \quad \&\& \quad y_i(\mathbf{w}\mathbf{x}_i + b) \neq 1 \\ \alpha_i &= C \quad \&\& \quad y_i(\mathbf{w}\mathbf{x}_i + b) > 1\end{aligned}$$

β

第二个变量的选取

由 (7) 式可知，要加快其迭代速度，就要使其变化量最大，即 $|E_1 - E_2|$ 最大，通常确定第二个参数的方法如下：1、在非界乘子中寻找使得 $|E_1 - E_2|$ 最大得样本；2、如果步骤 1 中没有找到则从随机位置查找非界乘子样本；3、如果步骤 2 中也没有找到，则从随机位置查找整个样本（包含界上和界下乘子）

以上就是 SMO 算法的基本思想，通常，SMO 算法的一般过程为：

1、启发式的选出两个参数 α_i, α_j ，所谓启发式的选择方法，即

第一个参数 α_i 的选择：首先遍历整个样本后选择违反 KKT 条件的 α_i 作为第一个变量，通常称这一过程为外循环。违反 KKT 条件的 α 满足下面式子：

$$\begin{aligned}\alpha_i &= 0 \quad \&\& \quad y_i(\mathbf{w}\mathbf{x}_i + b) < 1 \\ 0 \leq \alpha_i &\leq C \quad \&\& \quad y_i(\mathbf{w}\mathbf{x}_i + b) \neq 1 \\ \alpha_i &= C \quad \&\& \quad y_i(\mathbf{w}\mathbf{x}_i + b) > 1\end{aligned}$$

第二个参数 α_j 的选择：使 $|E_i - E_j|$ 能够取得最大值 (E_i 表示误差值，等于预测值减去标签值，即 $E_i = f(\mathbf{x}_i) - y_i, f(\mathbf{x}_i) = \mathbf{w}\mathbf{x}_i + b$)。

2、更新参数 α_i, α_j 的值，首先在这直接给出下列式子 (其中 $\gamma = \alpha_i y_i + \alpha_j y_j$, α_{iold} 表示更新前的 α_i 值, α_{inew} 表示更新后的 α_i 值, $\alpha_{jnew,clipped}$ 表示修剪过的满足 $0 \leq \alpha_j \leq C$ 的 α_j 值，以此类推)

$$\begin{aligned}\alpha_{jnew} &= \alpha_{jold} + \frac{y_j(E_i - E_j)}{\eta} \\ \alpha_{jnew,clipped} &= \begin{cases} L & \alpha_{jnew} \leq L \\ \alpha_{jnew} & L < \alpha_{jnew} < H \\ H & \alpha_{jnew} \geq H \end{cases} \\ L &= \begin{cases} \max\{0, \alpha_{iold} + \alpha_{jold} - \gamma\} & y_1 y_2 = 1 \\ \max\{0, \alpha_{jold} - \alpha_{iold}\} & y_1 y_2 = -1 \end{cases}\end{aligned}$$

$$H = \begin{cases} \min\{C, C + \alpha_{old} - \alpha_{j_{old}}\} & y_1 y_2 = -1 \\ \min\{C, \alpha_{j_{old}} + \alpha_{old}\} & y_1 y_2 = 1 \end{cases}$$

$$\alpha_{new} = \alpha_{old} + y_1 y_2 (\alpha_{j_{old}} - \alpha_{j_{new,clipped}})$$

3、不断重复以上步骤，直到所有的 α 都满足 $0 \leq \alpha_i \leq C$ 。

惩罚因子 C :

在二分类问题中，两个类别之间并不是完全分离的，一个类别中可能包含少量另一个类别的离群点，我们称其为噪声，为了减小这些噪声对分类结果的影响，在支持向量机中，我们引入了软间隔这一概念，即为每个样本点引入松弛变量 ξ_i ，把 (1) 式中的优化问题变成如下形式：

$$\min_{\mathbf{w}, b} f(\mathbf{w}, b) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \quad s.t. \quad y_i(\mathbf{w} \mathbf{x}_i + b) \geq 1 - \xi_i, \quad i = 1, \dots, n \quad \xi_i \geq 0 \quad (8)$$

由上式可以看出，离群点的松弛变量越大，点就离间隔边距越远，没有离群的点其松弛变量即为零。 C 被称为惩罚因子，值越大，对离群点的惩罚就越大，最终较少的离群点跨过边界，形成的模型也相对复杂，值越小，则对离群点的惩罚就越小，较多的点会跨过间隔边界，形成的模型较为平滑。

1.4 SMO 算法的代码实现

先创建一个 SMO 类，
 计算核函数
 计算期望值
 启发式的选择第二个参数：
 修剪 α 参数
 更新期望值
 内循环：
 外循环：